### Buffer Overflow – Uma introdução Teórica

Raphael Duarte Paiva

Equipe de Pesquisa e Desenvolvimento



GRIS – Grupo de Resposta a Incidentes de Segurança DCC – IM - UFRJ

### Buffer Overflow – Uma introdução Teórica

- Duas partes:
- Introdução
- Dissecando

### Buffer Overflow – Uma introdução Teórica

- Um breve histórico
- Buffer o que é?
- Overflow
- Buffer Overflow Uma visão geral
- Exploits

### Buffer Overflow – Um breve histórico

- Morris Worm 1988
  - Segundo o autor, o worm tinha o objetivo de medir o tamanho da internet.
- Utilizou uma falha no finger (uma chamada à gets()) para se copiar para outras máquinas.
- Um critério muito rigoroso para decidir se iria se copiar para um host ou não foi o que o tornou maléfico.
- Vários processos rodando = consumo de recursos, tanto da própria máquina quanto da rede.
- Teve um impacto devastador na época, atingindo 6000 computadores aproximadamente 10% da internet da época.
- Robert Morris, o autor do worm, foi sentenciado à um período probatório de 3 anos, 400 horas de serviço comunitário e multado em US\$10.500,00

### Buffer Overflow – Buffer – o que é?

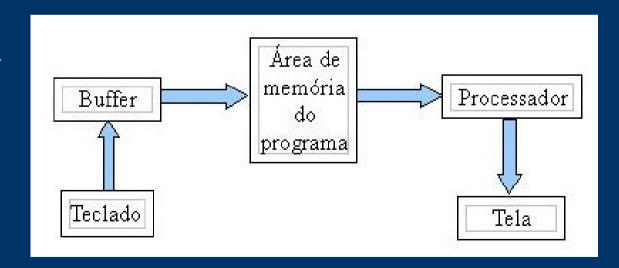
- Uma região temporária de memória utilizada para guardar dados que serão transportados de um lugar para o outro

#### - Exemplos:

- Um programa que recebe dados direto do teclado e os imprime na tela, i.e.

#### Terminal.

- Uma pessoa copiando a matéria de um quadro-negro.



#### **Buffer Overflow - Overflow**

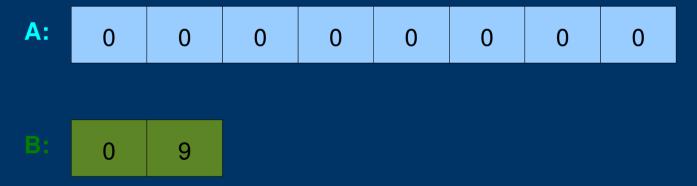
- Transbordamento



- Tecnicamente, o buffer overflow consiste em armazenar em um buffer de tamanho fixo, dados maiores que o seu tamanho.

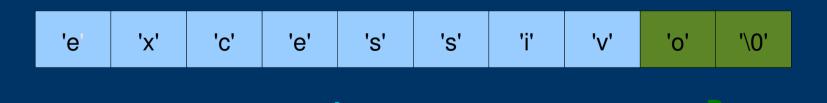


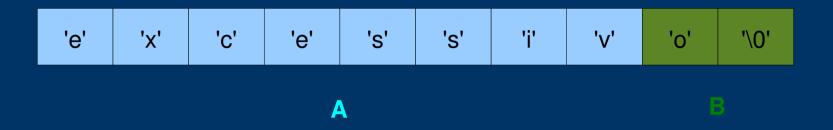
- Exemplo:
- Duas estruturas de dados adjacentes: A (vetor de caracteres de 8 bytes) e B (inteiro de 2 bytes)



- O que aconteceria se tentássemos inserir a palavra "excessivo" em A?

- "excessivo" ocupa 10 caracteres 'e', 'x', 'c', 'e', 's', 'i', 'v', 'o', \0', para o computador.
- '\0' indica o final da string, que é um vetor de caracteres.
- Cada caractere ocupa 1 byte em memória.
- Logo, A, que tem 8 bytes, será transbordado e os dados excedentes serão armazenados em uma posição adjacente na memória:





- A "transbordou" e os 2 bytes excedentes foram armazenados em B.
- Quando B for lido como um inteiro em um sistema little-endian, seu valor será igual a concatenação dos valores binários de '\0' e 'o', nesta ordem, ou seja: B = 000000001101111, que corresponde ao inteiro 111.

- Quais seriam as consequências?
  - Funcionamento errôneo do programa
- Uma string maior resultaria na tentativa de escrita de uma região de memória que não pertence ao programa, resultando numa falha de segmentação.
- Erros deste tipo em programas maiores podem levar à bugs desastrosos, horas de trabalho perdidas com depuração e falhas de segurança que podem levar ao surgimento de exploits, possivelmente causando grandes transtornos à todos que usam o programa.

#### - Exploits

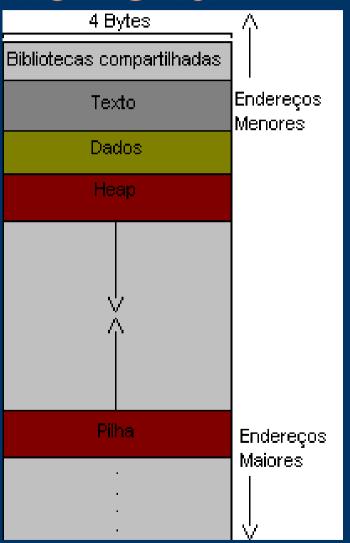
- Pedaços de código com o objetivo de se aproveitar de bugs ou falhas de segurança em softwares.
  - Podem causar comportamento errôneo, inesperado de um programa.
- Podem ter o objetivo de prover acesso privilegiado ao sistema, local ou remotamente.
- Tipos mais comuns de ataques baseados em buffer overflow:
  - Stack-based buffer overflow
  - Heap-based buffer overflow
  - Return-to-libc attack

#### Buffer Overflow - Dissecando

- A Estrutura de um programa na memória
- Conhecendo melhor a pilha
- Uma visão mais detalhada
- Técnicas de buffer overflow

### Buffer Overflow – A estrutura de um programa na memória

- A memória se divide em 4 partes:
  - Texto
  - Dados
  - Heap
  - Pilha



# Buffer Overflow – Conhecendo melhor a pilha

- A pilha consiste de frames empilhados
- Para cada subrotina (função) de um programa que é chamada, cria-se um frame, que é colocado no topo da pilha para a execução da mesma.

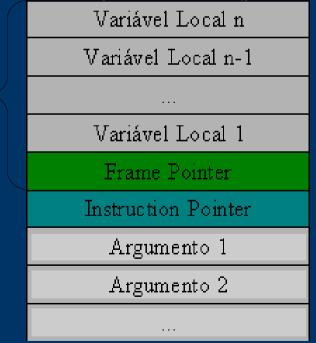
- Ao término da execução de uma subrotina, o frame é retirado do topo e a execução

Payload Space

do programa continua do frame anterior.

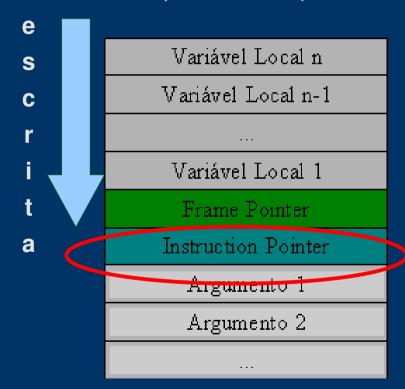
- Um frame contém as seguintes informações sobre a subrotina associada:

- Variáveis locais
- Frame Pointer
- Instruction Pointer
- Argumentos (parâmetros) da subrotina



## Buffer Overflow – Uma visão mais detalhada

- Em um escopo mais específico, podemos agora definir um "alvo" para um ataque.
- Só podemos escrever em uma direção na memória
- Alterando o Instruction Pointer, podemos direcionar a execução do programa para onde quisermos!



```
- Qual seria a saída do seguinte programa?
#include <stdio.h>
int main(void)
    int x;
    x = 0;
    x = 1;
    printf("%d\n", x);
    return 0;
```

- Existe uma maneira de "pular" uma instrução deste programa?
  - Sim! O exemplo a seguir mostrará o procedimento para pularmos a instução "x
- = 1", para que a saída do programa seja "0".
- Precisamos então redirecionar a execução do programa logo após a instrução "x = 0".
- Vamos adicionar a chamada à uma função logo após "x = 0":

```
int main(void)
     int x;
     x = 0;
     f();
     x = 1;
     printf("%d\n", x);
     return 0;
```

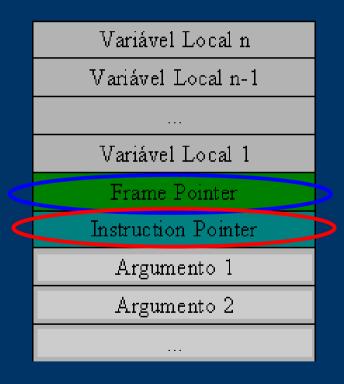
- Qual deve ser o conteúdo de f()?
  - Quando f() for chamada será criado um frame que conterá:

```
- Um "inicio" de f():
void f(void)
{
     char buffer[8];
}
```

- Na memória, buffer[8] ficaria:
  - buffer[0]
  - buffer[1]
  - (...)
  - buffer[6]
  - buffer[7]



- Como buffer[8] foi a primeira estrutura de dados declarada, logo após o espaço reservado para ela, está o frame pointer.
- 4 bytes depois está o nosso alvo: o Instruction Pointer.
- Precisamos agora reescrever o Instruction pointer.
- Em C, podemos criar um ponteiro e fazê-lo apontar para o Instruction Pointer.
- Assim, poderemos mudar o valor armazenado no Instruction Pointer.



```
void f(void)
{
    char buffer[8];
    int *ret;

    ret = 0/*endereço do IP*/;

    (*ret) = 0/*endereço da instrução desejada*/;
}
```

- Criamos o ponteiro \*ret, mas agora, como vamos descobrir o endereço do IP e o endereço da instrução desejada?

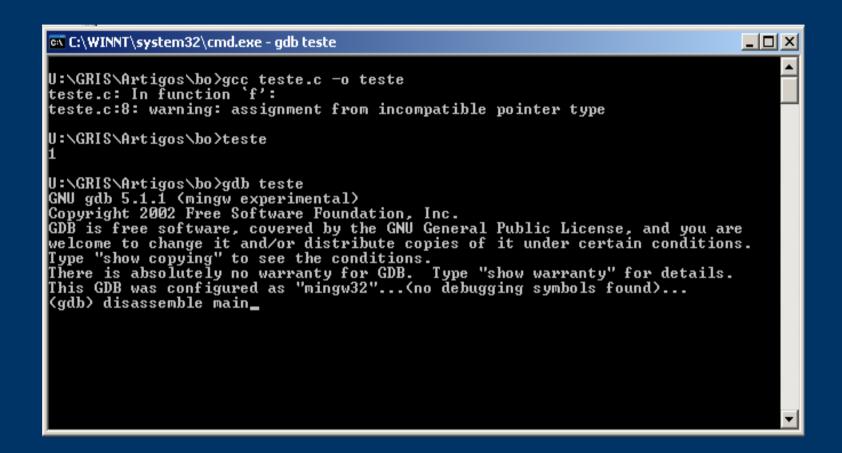
- Os endereços do IP e das instruções de um programa, em certos ambientes ficam em um mesmo espaço durante uma mesma sessão.
- Como queremos que o programa funcione em sessões diferentes, vamos utilizar valores relativos:

- Temos um buffer de caracteres de 8 posições (8 bytes) e um espaço (frame pointer) de 4 bytes antes do Instruction Pointer.
- Então concluimos que a distância entre o primeiro endereço de buffer[8] e o IP é de 8 + 4 = 12 bytes.
- ret = buffer + 12; // ret agora guarda o endereço do IP

- Para descobrirmos o endereço para reescrever o IP, precisamos olhar o código assembly do programa, então compilemos o seguinte código:

```
int main(void) {
#include <stdio.h>
                                                 int x;
void f(void)
                                                 x = 0;
     char buffer[8];
                                                 f();
     int *ret;
                                                 x = 1;
     ret = buffer + 12;
                                                 printf("%d\n", x);
     (*ret) += 0;
                                                 return 0;
```

```
C:\WINNT\system32\cmd.exe
U:\GRIS\Artigos\bo>gcc teste.c -o teste
teste.c: In function `f':
teste.c:8: warning: assignment from incompatible pointer type
U:\GRIS\Artigos\bo>teste
U:\GRIS\Artigos\bo}_
```



```
C:\WINNT\system32\cmd.exe - adb teste
                                                                                (qdb) disassemble main
Dump of assembler code for function main:
0x4012a0 <main>:
                         pus h
                                zebp.
0x4012a1 <main+1>:
                                zesp,zebp
                         mov
Øx4012a3 <main+3>:
                                 $0x8,%esp
                         sub
                                $0xfffffff0,%esp
0x4012a6 <main+6>:
                         and
0x4012a9 <main+9>:
                                 $0x0,%eax
                         mov
0x4012ae <main+14>:
                                %eax.Øxfffffffffffff(%ebp)
                         mov
0x4012b1 <main+17>:
                                0xffffffff8(%ebp), %eax
                         mov
0x4012b4 <main+20>:
                                0x402980 <_alloca>
                         call
0x4012b9 <main+25>:
                                0x4013c0 < __main>
                         call
0x4012be <main+30>:
                                $0x0,0xfffffffc(%ebp)
                         mov1
0x4012c5 <main+37>:
                                0x401280 (f)
                         call
                                $0x1.0xfffffffc(%ebp)
0x4012ca <main+42>:
                         mov1
                                $0x8,%esp
0x4012d1 <main+49>:
                         sub
                                Øxfffffffc(%ebp)
0x4012d4 <main+52>:
                         pushl
0x4012d7 <main+55>:
                         push
                                $0x40129b
                                0x402a30 (printf)
0x4012dc <main+60>:
                         call
                                $0x10,%esp
0x4012e1 <main+65>:
                         add
0x4012e4 <main+68>:
                                 $0x0.%eax
                         mov
0x4012e9 <main+73>:
                         leave
0x4012ea <main+74>:
                         ret
0x4012eb <main+75>:
                         nop
0x4012ec <main+76>:
                         nop
 --Type <return> to continue, or q <return> to quit-
```

- Temos então que o endereço de retorno original é 0x4012ca e o endereço do início da printf() é 0x4012d4.
- Então se somarmos ao endereço de retorno original a diferença dele mesmo com o endereço do inicio do printf(), teremos f() retornando sempre para o printf().
- -0x4012d4 0x4012ca = 0xA;
- Com isso, podemos completar o código:

```
#include <stdio.h>
                                     int main(void)
void f(void)
                                           int x;
     char buffer[8];
                                           x = 0;
     int *ret;
                                           f();
     ret = buffer + 12;
                                           x = 1;
     (*ret) += 0xA;
                                           printf("%d\n", x);
                                           return 0;
```

```
_ | | ×
C:\WINNT\system32\cmd.exe
0x4012b1 <main+17>:
                               mov
                               0x402980 <_alloca>
0x4012b4 <main+20>:
                        call
                               0x4013c0 < __main>
0x4012b9 <main+25>:
                        call
0x4012be <main+30>:
                        mov1
                               $0x0.0xfffffffc(zebp)
0x4012c5 <main+37>:
                        call
                               0x401280 <f>
                               $0x1,0xfffffffc(%ebp)
0x4012ca <main+42>:
                        mov1
0x4012d1 <main+49>:
                               $0x8,%esp
                        sub
0x4012d4 <main+52>:
                        pushl
                               Øxfffffffc(%ebp)
0x4012d7 <main+55>:
                               $0×40129b
                        push
0x4012dc <main+60>:
                               0x402a30 <printf>
                        call
                               $0x10,%esp
0x4012e1 <main+65>:
                        add
                               $0x0, %eax
0x4012e4 <main+68>:
                        mov
0x4012e9 <main+73>:
                        leave
0x4012ea <main+74>:
                        ret
0x4012eb <main+75>:
                        nop
0x4012ec <main+76>:
                        nop
---Type <return> to continue, or q <return> to quit---q
Quit (expect signal SIGINT when the program is resumed)
Čαdb> α
U:\GRIS\Artigos\bo>gcc teste.c -o teste
teste.c: In function 'f':
teste.c:8: warning: assignment from incompatible pointer type
U:\GRIS\Artigos\bo}_
```

```
C:\WINNT\system32\cmd.exe
0x4012be <main+30>:
                               $0x0.0xffffffffc(%ebp)
                        mov1
                               0x401280 <f>
0x4012c5 <main+37>:
                        call
0x4012ca <main+42>:
                               $0x1,0xfffffffc(%ebp)
                        mov1
                               $0x8,%esp
Øx4Ø12d1 <main+49>:
                        sub
0x4012d4 <main+52>:
                               0xfffffffc(%ebp)
                        pushl
0x4012d7 <main+55>:
                               $0x40129b
                        push
0x4012dc <main+60>:
                               0x402a30 (printf)
                        call
0x4012e1 <main+65>:
                               $0x10, %esp
                        add
                               $0x0.%eax
0x4012e4 <main+68>:
                        mov
0x4012e9 <main+73>:
                        leave
0x4012ea <main+74>:
                        ret
0x4012eb <main+75>:
                        nop
0x4012ec <main+76>:
                        nop
---Type <return> to continue, or q <return> to quit---q
Quit (expect signal SIGINT when the program is resumed)
(gdb) g
U:\GRIS\Artigos\bo>gcc teste.c -o teste
teste.c: In function 'f':
teste.c:8: warning: assignment from incompatible pointer type
U:\GRIS\Artigos\bo>teste
U:\GRIS\Artigos\bo>
```

# Buffer Overflow – Técnicas e shellcodes

- Stack-based buffer overflow
- A estrutura de um shellcode
- Conhecendo melhor a Heap
- Heap-based buffer overflow
- Return-to-libc attack

# Buffer Overflow – Stack-based buffer overflow

- As informações necessárias:
  - O tamanho do payload space
  - O intervalo na memória em que o payload space se encontra
- Com estas informações podemos executar um buffer overflow baseado em pilha:
  - Devemos inserir o código no formato de bytes no payload space dado.
  - Após o payload space, temos o nosso alvo: o Instruction Pointer.
- Devemos reescrever o Instruction Pointer com o endereço do início do código inserido.
- Deste modo, quando a subrotina terminar, o programa irá continuar sua execução no endereço guardado pelo Instruction Pointer, ou seja: o código inserido.

#### Buffer Overflow - ShellCodes

- São códigos legíveis ao processador
- Seu formato é em bytes
- Geralmente são passados a um programa na forma de String
- Na forma de String, cada byte é representado do seguinte modo : "\xNN", onde:
  - '\' significa que estamos passando um byte (não um caractere)
  - 'x' significa que o valor do byte está na base hexadecimal
  - NN é o valor do byte, na base hexadecimal

## Buffer Overflow – ShellCodes: Cuidados

- Como o shellcode é uma string, quando é passado para um programa neste formato, aquele será processado como uma string, então alguns cuidados em relação a bytes especiais devem ser tomados:
- '\x00' ou simplesmente '\0': caractere terminador de string. Ao chegar em um byte nulo, o processamento da string pára, pois as funções que trabalham com string interpretam o '\0' como o seu fim.
- '\x0A' e '\x0B' (\n): este byte, linefeed, pode quebrar o shellcode em duas linhas, o que representa outro problema.
  - Dentre outros...
- Para se contornar estes problemas, torna-se necessário o conhecimento da linguagem de máquina.

### Buffer Overflow – ShellCodes: Exemplo

- No caso de querermos construir um shellcode que imite a função system(), devemos seguir os seguintes passos:
- Construir um programa que chame a função system com o argumento referente ao comando de sistema que desejamos executar
- Analisar o código assembly do programa, por meio de uma ferramenta, como o gdb, conseguindo assim acesso ao código assembly da função system()
- Com o gdb, podemos ter acesso aos bytes referentes a cada instrução pelo comando "x/bx <nome\_da\_função>"
- Com os bytes em mão, podemos contruir o ShellCode, concatenando os bytes em uma string, tomando os cuidados e adaptações necessários.

### Buffer Overflow – ShellCodes: Exemplo

- Com o shellcode pronto, devemos preparar a string maliciosa na seguinte organização:
  - Dados para encher o buffer até o início do shellcode
  - O shellcode em si
- O valor para reescrever o Instruction Pointer com o endereço do início do shellcode
- Um problema comum: aleatoriedade da memória
- Este problema pode ser contornado utilizando shellcodes bem menores que o payload space e precedidos de bytes NOP ('\x90')

# Buffer Overflow – Conhecendo melhor a Heap

- A Heap é usada para alocação dinâmica de memória.
- Seu tamanho é ajustável.
- Binários possuem o Optional Header, que dá informações ao Sistema Operacinal sobre o quão grande a Heap é esperada.
- Cresce na direção oposta da pilha.
- Além do espaço para dados do programa, um bloco na Heap possui outros dados de organização, como:
  - Tamanho do bloco
  - Espaço utilizado
  - Próximo bloco
  - Bloco anterior
- Tais dados de organização são dependentes de implementação da Heap
- Não há como definir limites para o espaço da Heap em um programa, pois este é variável, nem o processador nem o kernel são capazes de detectar overflows na heap.

# Buffer Overflow – Heap-based buffer overflow

- Esta é uma técnica muito mais dificil de se explorar
- Dificuldades:
- Na heap não existem valores os quais o processador usa para saber qual a próxima operação.
- A heap cresce na mesma direção em que escrevemos na memória, então não é possível reescrever dados de organização do bloco em que o programa grava, apenas blocos posteriores
- Como a organização do Heap pode variar, o atacante deve conhecer a implementação utilizada pelo programa

# Buffer Overflow – Heap-based buffer overflow

- Para explorar um overflow na heap, é necessário achar um vulnerabilidade em alguma função interna de administração da heap, tal que esta função processe os dados em um bloco da heap.
- Precisamos explorar a heap para sobrescrever os valores de administração de um bloco alvo e então inserir o shellcode
- Os valores de administração devem ser alterados de forma a que este bloco seja processado diretamente por alguma subrotina, como a free(), ou de um modo em que a free() a processe de um meio especial, chamando uma outra subrotina.
- Além do passo anterior, os dados no bloco devem ser reescritos de modo a causar um overflow no frame da subrotina, para assim direcionar a execução do programa para o shellcode inserido.

# Buffer Overflow – Algumas questões

- Mas por que um shellcode na heap, se também temos que explorar uma vulnerabilidade na pilha?
  - Questão do espaço.
- Questão da pilha não-executável.
- Não importa onde você esteja, a libc estará sempre lá!
- A libc encontra-se em uma região restrita da memória.

## Buffer Overflow – Return-to-libc attack

- A idéia aqui é basicamente a mesma do buffer overflow baseado em pilha.
- Devemos, porém, reescrever o Instruction Pointer com o endereço de uma função da libc.
- O endereço de uma função da libc pode ser descoberto com um programa teste.
- Devemos então escrever na memória no seguinte esquema:
  - Reescrever o Instruction Pointer do frame alvo
  - O endereço de retorno da função da libc
  - Os argumentos da função alvo da libc

#### Buffer Overflow - Conclusões

- É um erro de implementação
- Anti-vírus não apresentam soluções diretas aos problemas.
- Existem programas que dependem de pilhas executáveis, como o JRE, por exemplo.

- Algumas dicas desenvolvimento sobre como se evitar transtornos com buffer overflows:
  - Usar bibliotecas seguras
  - Sempre fazer verificação de fronteiras, quando fazendo uso de strings
  - Utilizar uma implementação própria de heap

#### Buffer Overflow – Fim!

Dúvidas?

Obrigado!

raphaelpaiva@gris.dcc.ufrj.br www.gris.dcc.ufrj.br

Raphael Duarte Paiva

Equipe de Pesquisa e Desenvolvimento

GRIS – DCC – IM - UFRJ